Оптимизация строковой решетки для статического анализа кода на базе абстрактной интерпретации

Студент: Можаев Андрей Михайлович
Руководитель: Кичин Егор Андреевич
Университет ИТМО

2025

Предметная область

- **Абстрактная интерпретация** – метод **статического анализа**, который аппроксимирует поведение программы, работая с абстрактными значениями вместо конкретных. Позволяет анализировать все возможные пути выполнения без запуска программы
- **Решетки** – это частично упорядоченное множество, обобщающее возможные значения переменной. Они используются для перехода между абстрактными значениями

Текущая строковая решетка

Точность абстракци низкая – str.length невозможно оценить, т.к. знаем только то, что str – обычная строка. Поэтому интерпретатор видит деление на 0 там, где его нет

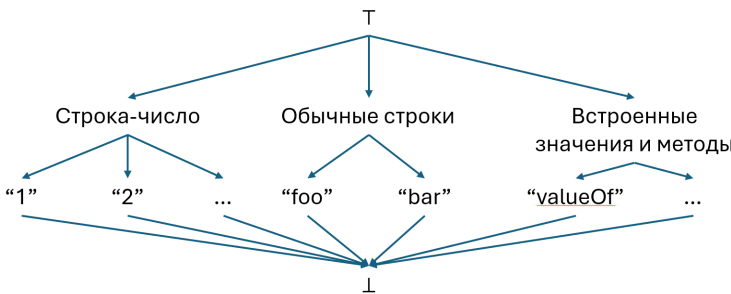


```
string str;
if (b) {
    str = "foo";
} else {
    str = "bar";
}
return 100 / str.length;
```

Цель и задачи

Цель: повысить точность строковой решетки, используемой в статическом анализаторе кода на базе абстрактной интерпретации

Задачи:

1. Провести обзор существующих строковых абстрактных решеток
2. Спроектировать структуру более точной строковой решетки на их основе
3. Реализовать операции для работы с абстрактными значениями строк и интегрировать в статический анализатор
4. Протестировать новую функциональность, провести замеры производительности статического анализатора при использовании новой решетки

Существующие решения

Домен	Операции	Работа с $\top$	Скорость
Abstract Length	length	Минимальная длина	Высокая
Character Inclusion	contains	Только символы	Высокая
Prefix-Suffix	starts/endsWith substring	Префиксы суффиксы	Высокая
String Set (SS_k)	Все	Переполнение в $\top$	Средняя
Конечные автоматы	Все	Через $\top$-переходы	Очень низкая
TARSIS[1]	Все (с ограничениями)	Через $\top$-переходы	Средняя

За основу был выбран подход TARSIS, так как обладает хорошей точностью при средней производительности

[1] Arceri V. et al. TARSIS: Abstract Domains for String Analysis (2022) DOI: 10.48550/arXiv.2006.02715

Структура решетки

Можество значений строк можно представить в виде автомата. На автоматах задан порядок по включению, есть операции объединения и пересечния

$$\langle \mathcal{T}F_A, \sqsubseteq_{\mathcal{T}}, \sqcup_{\mathcal{T}}, \sqcap_{\mathcal{T}}, Min(\emptyset), Min(\mathbb{A}^*) \rangle$$

- $\mathbb{A}^* = \Sigma^* \cup \{\top\}$ – Алфавит, состоящий из слов и специального символа $\top$, означающего любую строку
- $\mathcal{T}F_A$ – Множество автоматов над алфавитом $\mathbb{A}^*$
- $\sqsubseteq_{\mathcal{T}}$ – Частичный порядок на автоматах, основанный на включении языков
- $\sqcup_{\mathcal{T}}$ и $\sqcap_{\mathcal{T}}$ – Наибольший (join) и наименьший (meet) общий по включению элемент в решетке
- $Min(\emptyset)$ – Автомат, принимающий пустой язык, или $\bot$
- $Min(\mathbb{A}^*)$ – Автомат, принимающий любой язык, или $\top$

Пример

```
str = ""
if (play) {
    coin = tossCoin()
    str = "toss coin" + coin + calcBet(coin)
} else if (greetings) str = "hello " + name()
```

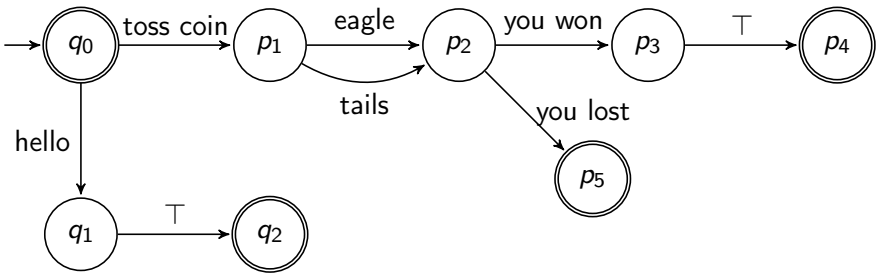

Реализованные операции

- Операции для работы с автоматами
  - Для решеток – **join ($A \cup B$), meet ($A \cap B$), weakerThen ($A \subset B$)**
  - Вспомогательные – **minimize, explode, collapse, getLanguage**
- Строковые операции. Работая с автоматами, то есть множеством возможных строк, определяем множество возможных значений при применении операции
  - TARSIS – **length, concat, contains, substr, replace, indexOf**
  - Дополнительно реализованные – **charAt, starts/endsWith, trim, pad, toBool, toNum, strLt**
- Так как решетка содержит бесконечную цепочку вложенных автоматов, то для нахождения неподвижной точки при анализе циклов реализован оператор расширения – **widening**

Новая функциональность

```
function tossCoin(): string {
    if (Math.Random() > 0.5) {
        return "eagle"
    } else {
        return "tails"
    }
}

let x = tossCoin()           // Было -> Стало
console.log(x.indexOf("a")) // ⊤    -> [number: [1, 1]]
console.log(x.indexOf("e")) // ⊤    -> [number: [-1, 4]]
console.log(x.indexOf("r")) // ⊤    -> [number: [-1, -1]]
```

Новая функциональность

```
var x = "Hello " + name()        // Было -> Стало
console.log(x)                   // ⊤    -> [string: Hello ⊤]
console.log(x.length)            // ⊤    -> [number: [6, +Inf]]
console.log(x.startsWith("He")) // ⊤    -> [boolean: true]
console.log(x.substr(0, 4))      // ⊤    -> [string: Hell]
```

Сравнение точности

Сравниваем количество возвращаемых значений функций при анализе

Операция	Значение	Было	Стало	Изменение
Concat	Top	319,381	25,331	↓ 92%
	Const	58,321	58,767	↑ 1%
	Automaton	0	298,822	-
Возвращает String	Top	4,587	3,610	↓ 22%
	Const	795	1,363	↑ 71%
	Automaton	0	201	-
Возвращает Number	Top	823	426	↓ 48%
	NonTop	477	801	↑ 68%
Возвращает Boolean	Top	15,470	14,326	↓ 7%
	NonTop	199	287	↑ 44%

В среднем точность строковых операций возросла на 67%

Сравнение производительности

Сравниваем время анализа, количество проанализированных состояний программы и среднее потребление памяти всего анализатора

Тип	Метрика	Было	Стало	Изменение
Суммарно	Время (мин)	28:25	33:23	↑ 18%
	Состояния	35.7 млн	35.3 млн	↓ 1%
Малые до 30 сек	Время	0:22	0:22	↑ 0%
	Память	4к МБ	4.3к МБ	↑ 7%
Средние 0.5-5 мин	Время	1:19	1:38	↑ 24%
	Память	7.1к МБ	6.8к МБ	↓ 4%
Большие от 5 мин	Время	8:26	8:46	↑ 4%
	Память	17.9к МБ	16.7к МБ	↓ 7%

Сокращение памяти обусловлено тем, что меньше состояний программы сохраняется

Open Source

Операция	Метрика	Было	Стало	Изменение
Суммарно	Время (мин)	2:39	3:12	↑ 20%
	Состояния	5.47 млн	5.29 млн	↓ **3%**
Concat	Top	17,457	3,908	↓ 78%
	Const	2038	2029	↓ 1%
	Automaton	0	13,247	-
Возвращает String	Top	130	117	↓ 10%
	Const	55	62	↑ 13%
	Automaton	0	12	-
Возвращает Number	Top	24	5	↓ 80%
	NonTop	3	22	↑ 633%
Возвращает Boolean	Top	3090	3010	↓ 3%
	NonTop	3	8	↑ 167%

Результаты

- На основе обзора строковых абстрактных доменов выбран подход TARSIS
- На базе его спроектирована структура строковой решетки
- Разработанная решетка реализована и интегрирована в статический анализатор кода.
- Удалось повысить точность анализа строковых операций на 67% в среднем
- Суммарное время исполнения увеличилось не более, чем на 20%
- Количество потребляемой памяти в больших и средних проектах немного уменьшилось (до 7%) за счет сокращения количества проанализированных состояний

Дополнительные материалы

Анализатор

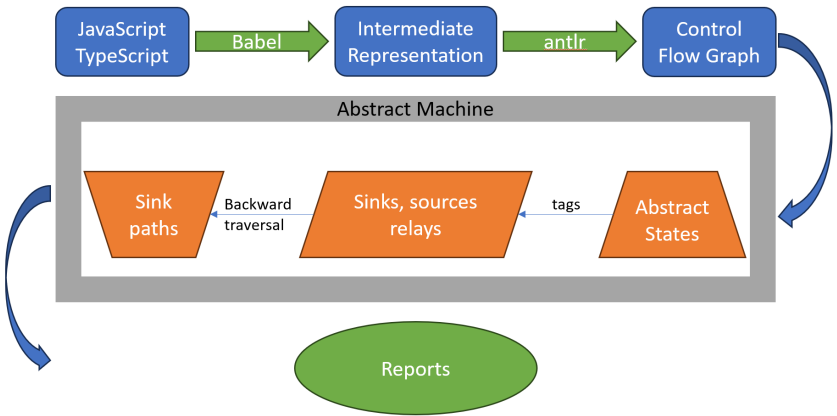
JavaScript
TypeScript
Babel
Intermediate
Representation
antlr
Control
Flow Graph
Abstract Machine
Sink
paths
Backward
traversal
Sinks, sources
relays
tags
Abstract
States
Reports

widening

```
res = "";
while(?) res = res + "id = " + f();
return res;
```

Начало второй итерации:

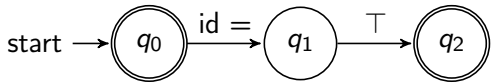

Конец второй итерации:

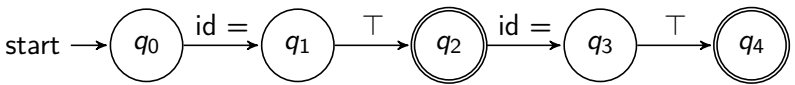

widening

Объединенное состояние после второй итерации:

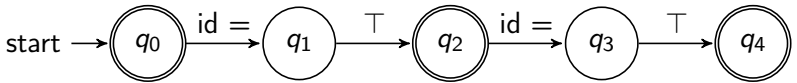

widening — Склеивание вершин с одинаковыми исходящими путями длины 2:

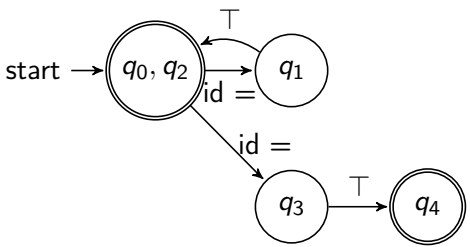

minimize:

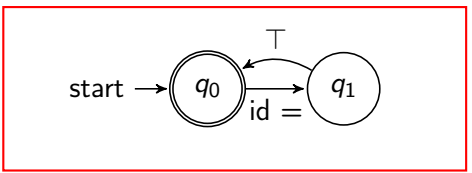

Операции

```
toNum():
    this.explode()
    foreach π ∈ paths(A, ⊤ → ⊘):
        if π has minusFirst:
            maxNum = max(maxNum, π)
            if π has cycle or ⊤: minNum = -∞
            else minNum = min(minNum, π)
        else:
            minNum = min(minNum, π)
            if π has cycle or ⊤: maxNum = ∞
            else maxNum = max(maxNum, π)

    return Int.Interval(minNum(), maxNum())
```

Операции

$$\text{contains}(s, s') \triangleq \begin{cases} \text{false} & \text{if } A' \sqcap \text{FA}(A) = \emptyset \\ \text{true} & \text{if } \neg\text{cyclic}(A) \wedge \text{singlePath}(A') \\ & \wedge \forall \pi \in \text{paths}(A).\sigma_{sp} \curvearrowright_s \sigma_\pi \\ \{\text{true}, \text{false}\} & \text{otherwise} \end{cases}$$

- FA(A) - Автомат, принимающий все подстроки A. Для этого все вершины A помечаем терминальными
- singlePath - Для любых двух слов, принимаемых автоматом, одно является префиксом другого. Или же автомат выглядит как путь, у которого некоторые вершины на пути помечены терминальными

Операции

- Union $A \cup B$ — Добавляем общее начало для обоих автоматов, затем минимизируем

```
minimize(a: Automaton): Automaton {
    return a.determinize().reverse().determinize().reverse();
}
```

Brzozowski's minimization algorithm

- determinize — приведение к детерминированному виду, то есть к отсутствию нескольких переходов с одинаковым символом из одной вершины, а также ε переходов (с пустой строкой)
- reverse — изменение ориентаций всех переходов, а также смена начальных состояний на конечные и наоборот

Операции

- Intersection $A \cap B$ — Прямое произведение автоматов

Theorem (Прямое произведение автоматов)

Для всяких двух DFA $\mathcal{A} = (\Sigma, P, p_0, \eta, E)$ *и* $\mathcal{B} = (\Sigma, Q, q_0, \delta, F)$*, пересечение* $L(\mathcal{A}) \cap L(\mathcal{B})$ *распознаётся DFA* $\mathcal{C} = (\Sigma, P \times Q, (p_0, q_0), \pi, E \times F)$*, где функция переходов действует покомпонентно* $\pi\big((p, q), a\big) = \big(\eta(p, a), \delta(q, a)\big)$

Операции

$$\mathsf{length}(s) \triangleq \begin{cases} [|\mathsf{minPath}(A)|, +\infty] & \text{if } \mathsf{cyclic}(A) \vee \mathsf{readsTop}(A) \\ [|\mathsf{minPath}(A)|, |\mathsf{maxPath}(A)|] & \text{otherwise} \end{cases}$$

$$\mathsf{indexOf}(s, s') \triangleq \begin{cases} [-1, +\infty] & \text{if } \mathsf{cyclic}(A) \vee \mathsf{cyclic}(A') \vee \mathsf{readsTop}(A') \\ [-1, -1] & \text{if } \forall \sigma' \in \mathcal{L}(A')\ \nexists \sigma \in \mathcal{L}(A).\sigma' \curvearrowright_s \sigma \\ \bigsqcup\limits_{\sigma \in \mathcal{L}(A')} \mathsf{IO}(A, \sigma) & \text{otherwise} \end{cases}$$